

轮腿机器人局部操纵的手臂约束课程学习

中文译稿 | 公式、图表编号和参考文献按原文保留

摘要：将机器人机械手融入轮腿机器人中可增强其敏捷性并扩展其实际应用潜力。然而，潜在的不稳定性和不确定性的存在给控制目标带来了额外的挑战。在本文中，我们引入了一种手臂约束的课程学习架构，以解决添加机械手带来的问题。首先，我们开发了手臂约束强化学习算法，以确保控制性能的安全性和稳定性。此外，为了解决手臂和底座之间奖励设置的差异，我们提出了一种奖励感知课程学习方法。该策略首先在 Isaac 体育馆进行训练，然后转移到物理机器人上执行动态抓取任务，包括开门任务、抽动风扇任务以及接力棒拾取和跟随任务。结果表明，我们提出的方法有效地控制配备手臂的轮腿机器人掌握动态抓取技能，使其能够在运动中追逐并捕捉移动物体。

请参阅我们的网站 (<https://acodedog.github.io/wheel-legged-loco-manipulation/>) 了解代码和补充视频。一、引言人类能够轻松完成各种复杂的任务，例如穿过有各种障碍的区域以及与不同的物体交互。然而，这些看似常见的任务给机器人掌握这些技能带来了许多挑战：机器人需要高速执行动态运动并与不同的物体交互，同时协调各个部分以确保安全。腿式机器人平台的出现为在各种不确定环境中执行复杂任务提供了可行的基础[1], [2]。通过将机械臂增强到移动机器人平台，例如四足机器人[3]、双足机器人[4]和轮腿机器人[5]等，可以实现更复杂的交互。其中，轮腿机器人结合了轮式和腿式机器人的优点，利用轮子的高能效和卓越的适应性，利用腿克服不平坦的地形和障碍物[6]。

使用深度强化学习 (DRL) 进行机器人全身控制和物体操纵的研究日益增长，它在学习提供了更高效、更灵活、更鲁棒的策略，并做出了平等的贡献。1香港科技大学 (广州)、2清华大学人工智能产业研究院 (AIR)、3清华大学电子工程系、4哈尔滨工业大学、5西交利物浦大学、6DISCOVER Robotics † 通讯作者。
eejinni@hkust-gz.edu.cn、jun.ma@ust.hk、zhouguyue@air.tsinghua.edu.cn 使机器人能够更轻松的理解如何完成各种复杂的任务[7]、[8]。将机器人操纵器与轮腿机器人集成可以增强灵活性并在实际应用中释放更大的潜力。然而，尽管对腿式机器人进行了广泛的研究，但轮腿式机器人的操纵能力仍存在严重差距。同时协调手臂和轮子的运动需要管理多种控制模式，每种模式都有自己的动态和约束，这给控制带来了额外的挑战。

另一方面，在移动手臂和轮子时平衡机器人会带来额外的动态稳定性要求。在这项工作中，我们提出了一种手臂约束课程 RL 用于轮腿机器人局部操纵的框架。受游戏启发的课程学习程序可以同时控制手臂和轮子。框架中引入了手臂约束网络，以保证机器人的安全性和稳定性。我们的新颖框架能够实现动态抓取，利用轮腿平台固有的稳定性、效率和速度优势，从而增强其物体操纵能力。本质上，本文做出了以下贡献：• 我们提出了一种专门为轮腿机器人的局部操纵而设计的手臂约束课程强化学习框架。该框架允许同时控制手臂和轮子，解决协调混合运动和操纵任务的稳定性、安全性和效率挑战。• 我们引入了奖励感知课程学习过程，旨在促进智能体所有组成部分的平衡进步，无论它们的奖励是稀疏还是密集。通过实施这种方法，可以降低系统陷入局部最小值的风险。

二.相关工作 A. 基于 RL 的腿式机器人控制 最近的研究表明，在腿式机器人系统中使用 RL 时，控制性能令人印象深刻 [9]、[10]、[11]、[12]、[13]。在[14]中，分布式强化学习被用来训练四足机器人的风险感知算法，使其能够动态地适应不同类型的地形。同时，[15]中的研究人员将本体感受数据与嘈杂的外感受信息相结合，以实现快速动态行走 arXiv:2403.16535v2 [cs.RO] Mar 图 1. 所提出的架构完成的任务。左上：开门、拉门任务；右上：风扇旋钮抽动任务；左下：接力棒追逐任务；右下：开门和推门任务。在各种地形上。然而，实现这种具有自然运动风格和高任务绩效的出色控制器通常需要细致的奖励塑造才能获得所需的行为[16]。

研究人员通过采用动作模仿技术、训练模拟角色的控制策略来复制在动物或人类中观察到的预先记录的动作来解决这个问题[17]。在训练过程中，奖励的使用鼓励策略模仿运动剪辑中的动作，从而无需进行大量的奖励调整。B. 腿式机器人的局部操纵利用配备手臂的多功能机器人平台可以实现动态物体操纵，这是一项具有挑战性的任务 [18][19][20]。在[21]中，提出了一种创新方法，可以同时识别全面的全身轨迹和接触序列，以解决预定义环境中的不同局部操纵场景。该方法集成了轨迹优化、知情图搜索和基于采样的规划，从而使四足移动机械臂能够产生可抓握

和非可抓握交互的紧急行为，使其能够执行现实世界的任务。在[22]的另一项研究中，开发了一种新颖的方法，它将基于学习的运动策略与基于模型的操纵相结合。这使得腿式移动机械手能够适应具有挑战性的地形并实现稳健的运动。

此外，[3]提出了一种通过学习单一统一策略来增强腿式机器人的多功能性的新方法。该策略促进了操纵任务（使用附加手臂）和运动之间的无缝协调，克服了传统分层控制管道的局限性。该方法利用强化学习、正则化在线适应和优势混合来弥合 Sim2Real 差距，并在各种任务设置中实现动态和敏捷的行为。三. 预备 在本节中，我们将介绍这项工作的技术预备知识。A. 约束马尔可夫决策过程 (CMDP) 强化学习问题的环境通常以马尔可夫决策过程的形式表示，这是一个用于建模决策问题的数学框架。它用一个元组 $(S, A, R, P, \rho, \gamma)$ 来描述，其中 S 表示状态空间， A 表示动作空间， $R \in \mathbb{R} : S \times A \rightarrow \mathbb{R}$ 是立即奖励函数， $P : S \times A \times S \rightarrow \mathbb{R}$ 是转移模型， γ 表示折扣因子。

约束马尔可夫决策过程 (CMDP) [23] 是传统 MDP 框架的一种变体，其中对状态-动作对或策略施加额外的约束，以满足决策过程中的特定要求或限制[24]、[25]。它通常用元组 $(S, A, R, P, C_1, \dots, C_K, \rho, \gamma)$ 来描述，附加参数 $C_k : S \times A \rightarrow \mathbb{R}$ 表示 $\forall k \in \{1, \dots, K\}$ 的成本函数， ρ 是初始状态分布。为了解决 CMDP，我们的目标是找到一个最大化策略 $\pi : J_R(\pi) = E \sum_{t=0}^{\infty} \gamma^t r(st, at, st+1) \# s.t. J_{C_k}(\pi) \leq dk \forall k \in \{1, \dots, K\}$ ，(1) 其中 J_{C_k} 是约束， dk 是约束阈值，期望 $E[\dots]$ 表示贴现的预期收益。

B. 约束近端策略优化 近端策略优化 (PPO) 是一种无模型强化学习算法，旨在通过迭代更新代理目标函数来找到最优策略 图 2. 所提出框架的总体说明。上：两阶段学习过程；底部：网络的详细表示。同时对政策更新的规模进行限制，从而实现稳定高效的学习。目标函数被描述为 $LPPO(\theta) = E_{s \sim d_{\pi}^a \sim \pi} h_{\pi}(\theta(a|s)) \pi_i(a|s) A_{\pi_i}(s, a) - \beta D_{KL}[\pi_{\theta}(\cdot|s), \pi_i(\cdot|s)]$ ，其中 D_{KL} 是 Kullback-Leibler 散度， β 表示策略的权重。惩罚性 PPO (P3O) [26] 是 PPO 算法的一种变体，其中在优化过程中纳入了额外的约束，以对学习的策略执行特定的标准或限制，确保在训练期间符合期望的行为或安全约束。

优化问题变为最大化 $\pi \in \Pi_{\theta} LP3O = LPPO(\theta) + K \sum_{k=1}^K \log dk - J_{C_k}(\pi_{\theta}) / J_{C_k}(\pi_{\theta}) = J_{C_k}(\pi) + 1 - \gamma E_{s \sim d_{\pi}^a \sim \pi} \theta(a|s) \pi_i(a|s) A_{\pi_i}(s, a)$ ，(2) 其中 J_{C_k} 表示由下式引入的约束函数附加约束 $C_k, k \in 1, \dots, K$ 。IV. 方法A. 结构概述 所提出的架构的概述如图2所示。整个结构遵循两阶段学习过程。最初，采用行为克隆过程来初始化参与者网络。随后，执行奖励感知课程学习过程，以迭代改进任务完成策略。具体来说，网络经过训练以遵循用户命令，其中包括两个部分：手臂所需的目标姿势和身体所需的速度。这些用户命令以及来自机器人的本体感觉信息作为手臂约束近端策略优化 (AC-PPO) 策略网络的输入（观察）。

AC-PPO框架由三个网络组成：行动者网络、奖励批评家网络和附加约束批评家网络。约束批评网络生成的安全信息被纳入用于引导机器人手臂的隐式规划参考中。该框架可以实现协调的混合运动和操纵任务。各组件的详细介绍如下。B. 手臂约束的近端策略优化 轮腿机器人的运动操纵最具挑战性的方面之一涉及有效协调运动和操纵，同时适应动态物体。为了确保操纵任务不会损害运动安全，我们将速度跟踪和运动操纵任务制定为 CMDP。为了解决上述挑战，我们将手臂的设计约束纳入 (2) 中，并训练 P3O 算法为手臂和腿生成稳定且安全的动作。具体来说，约束设计如下：1) 手臂关节约束：虽然动作空间可能会对动作的值施加一些约束，但在连续的动作空间中并不总是能够达到这些限制。此外，我们的目标是避免手臂关节位置持续达到极限的情况，这可能会对机器人的电机造成损害。

为了实现这一目标，我们施加联合立场限制，以鼓励尽可能远离限制的行动。这有助于减少不安全事件的发生 事件和不稳定的运动。表达式为： $C_{arm} = \sum_{i \in \text{手臂关节}} \|\max(q_i, t - q_{upper, i}, 0)\| + \sum_{i \in \text{手臂关节}} \|\min(q_i, t - q_{lower, i}, 0)\|$ 。2) 夹具位置约束：该约束与手臂质心与其底座质心之间的间隔距离有关。调整夹具的位置可能会改变机器人的整体重心，从而可能导致不稳定。为了降低操作任务期间翻倒的风险，施加此约束以保障机器人的稳定性并确保其安全。表达式描述为： $C_{Gripper} = \|(\text{Parm centroid} - \text{Pbase centroid})\|^2$ 。3) 碰撞约束：为了防止自碰撞以及机器人手臂与环境之间的碰撞，我们对施加在每个手臂连杆上的力 f_i 施加碰撞约束。

理想情况下，当未检测到碰撞时，该力应保持接近 0，表明处于平衡状态。强制执行这一约束对于确保机器人在其环境中安全运行至关重要。我们将约束表示为： $C_{force} = \sum_{i \in \text{arm links}} \|(f_{arm, i})\|^2$ 。C. 奖励意识课程学习 先前的研究强调了采用任务难度课程来训练复杂策略的优势[27]，[28]。基本概念涉及首先在较简单的任务上训练策略，然后逐渐增加复杂性。在我们的框架中，我们引入了奖励意识课程学习方法。我们没有调整任务的复杂性来实现课程目标，而是将智能体初始化为更接近目标姿势并逐步扩大范围。这对于解决稀疏奖励设置的挑战特别有益，因为代理可以在训练过程的早期阶段快速获得高奖励。

在复杂的机器人平台中，代理的不同组件的工作空间和奖励设置差异很大，我们可以通过采用这种奖励感知课程学习过程，鼓励代理中奖励稀疏的部分与奖励密集的部分更平等地进步。在这种特定场景中，与轮腿相比，机器人手臂具有更广泛的工作空间，但获得的奖励更少。因此，机器人可能会陷入局部最小值，在该局部最小值中，腿部会获得较高的奖励，从而导致手臂采取保守的动作，以避免影响腿部的稳定性。为了克服这一挑战并提高训练效率，采用了这种基于奖励的课程学习结构来鼓励手臂学习移动。我们将手臂的末端执行器初始化为靠近目标位置，从而实现相对简单的动作，从而在训练开始时获得高奖励。因此，当我们进一步增加到目标的距离时，它抵抗运动的可能性就会减小。

该过程的一个示例是： $P_{init\ ee} \sim N(\mu, \Sigma)$ s.t. $\mu = P_{goal}$, $\Sigma = 1 + t \cdot T \cdot D^2$, (3) 其中 $P_{init\ ee}$ 是机器人每次复位时的夹具位置。 μ 和 Σ 是高斯分布的均值和方差。 P_{goal} 是夹具的目标位置。 T 是最大情节长度， D 是最大期望目标距离。请注意，该过程的表达式可以轻松扩展到其他类型的分布。这种方法使腿和操纵器能够学习有效地跟踪参考。

D. 使用行为克隆的两阶段学习 如图 2 所示，实施了两阶段学习过程以确保架构的安全性和效率。在第一阶段，从目标环境中运行的全身控制器[29]收集数据。利用基线控制器可确保数据的安全生成，而不会危及机器人。随后，该数据集用于在后续阶段初始化参与者网络的参数，利用行为克隆技术来复制基线控制器做出的决策。

V. 实验 A. 实验设置 进行了几个实验来测试如图 3 所示的配备手臂的轮腿机器人的性能和稳定性，该机器人由轮腿底盘和机器人手臂组成。每条腿总共有 3 个电机：髋部电机、膝部执行器和驱动轮。此外，它还配备了一个 6 自由度串行机械臂 AIRBOT-Play 和一个作为末端执行器的夹具。两个摄像头分别安装在机器人底座和机械臂末端执行器上。电源由板载电池提供，计算也在板载完成。图 3. 配备手臂的轮腿机器人平台示意图。根据第 2 节中概述的架构来训练策略。

IV. 我们定义观察空间、动作空间和奖励如下： 1) 观察空间：观察空间由状态向量 $S_t = \{S_{base\ t}, S_{arm\ t}, S_{cmd\ t}\} \in R^{46}$ 构造。基的信息表示为 $S_{base\ t} = [h, v, \omega, R, q_{leg}, \dot{q}_{leg}, \dot{q}_{wheel}] \in R^{20}$ 。
arm 的观测值存储在 $S_{arm\ t} = \{q_{arm}, \dot{q}_{arm}, p_{ee}, R_{ee}\} \in R^{18}$ 中，并且图4. 仿真跟踪结果。 $S_{cmd\ t} = \{v_{cmd\ x}, w_{cmd\ z}, p_{cmd\ ee}, R_{cmd\ ee}\} \in R^8$ 包括控制命令。各参数的含义为：
• $h \in R^1$ ：底高。
• $v \in R^3$ ：基础线速度。
• $\omega \in R^3$ ：基础角速度。
• $R \in R^3$ ：基本方向。
• $q_{leg} \in R^4$ ：腿部关节位置。
• $\dot{q}_{leg} \in R^4$ ：腿部关节速度。
• $\dot{q}_{wheel} \in R^2$ ：轮关节速度。
• $q_{arm} \in R^6$ ：手臂关节位置。
• $\dot{q}_{arm} \in R^6$ ：手臂关节速度。
• $p_{ee} \in R^3$ ：夹具位置。
• $R_{ee} \in R^3$ ：夹具方向。
• $v_{cmd\ x} \in R^1$ ：x 轴线速度。
• $w_{cmd\ z} \in R^1$ ：z 轴角速度。

• $p_{cmd\ ee} \in R^3$ ：夹具目标位置。
• $R_{cmd\ ee} \in R^3$ ：夹具目标方向。
2) 动作空间：策略的动作向量 $A = \{A_\tau, A_{arm}\} \in R^{12}$ 由控制轮腿的关节扭矩 $A_\tau \in R^6$ 和驱动手臂的关节位置 $A_{arm} \in R^6$ 构成。关节位置矢量由低级控制器进一步处理，以获得驱动手臂所需的扭矩。
3) 奖励：如表所示。I，分别为轮式腿和手臂定义运动奖励和操纵奖励，两者都考虑了跟踪性能和安全性。B. 仿真测试首先在仿真中部署所提出的结构。我们使用 Isaac Gym 作为模拟器，并同时在 6000 个环境中训练策略。在训练开始时，身体的控制命令、基座的目标线速度和角速度是从区间 $v_{cmd\ x} = [-2, 2]m/s$ 和 $w_{cmd\ z} = [-0.5, 0.5]rad/s$ 上的均匀分布中选择的。然后机器人学会跟踪这个速度直到终止。

满足终止标准后，这意味着机器人学会跟踪当前表 I 奖励功能设置 运动奖励表达式 线速度跟踪 $\exp(-7.5 \cdot \|v_{cmd\ x} - v_x\|^2)$ 角速度跟踪 $\exp(-1.25 \cdot \|w_{cmd\ z} - w_z\|^2)$ 加速度限制 $-0.1 \cdot \|v_{last\ x} - v_x\|^2$ 方向罚分 $-1.2 \cdot \|R_y\|^2 - 1.2 \cdot \|R_x\|^2$ 能量损失 $-10 - 5 \cdot \|\tau\|^2$, τ : 电机扭矩 腿部运动 $-10 - 7(\|\dot{q}_{leg}\|^2 - 2.5 \|\ddot{q}_{leg}\|^2)$ 操纵奖励表达式 夹具位置跟踪 $\exp(-5 \cdot \|p_{ee} - p_{cmd\ ee}\|^2)$ 身体位置跟踪 $\exp(-0.05 \cdot \|p_{base} - p_{cmd\ base}\|^2)$ 机械臂位置上限 $-10 P \max(q_{arm,i,t} - q_{upper\ arm,i}, 0)^2$ 机械臂位置下限 $-10 P \min(q_{arm,i,t} - q_{lower\ arm,i}, 0)^2$ 速度，目标值重新采样。

在操纵器方面，我们采用了第 2 节中介绍的奖励感知课程学习过程。IV-C. 夹具的目标位置最初是从均值为 0 且标准差在较窄范围内的正态分布中采样的，对于 $p_{cmd\ ee}$ 为 $[0.5, 0.1, 0.2]m$ 。一旦奖励超过最大奖励的 90%，标准差的范围就会扩大，末端执行器的 x、y、z 方向的扩大步长为 $[0.5, 0.1, 0.1]m$ 。在转移到物理机器人之前，我们在模拟中验证了算法的性能。选择基底命令速度的三种情况为{情况1: $v_{cmd\ x} = 0.5m/s$, $w_{cmd\ z} = 0rad/s$ }、{情况2: $v_{cmd\ x} = 0m/s$, $w_{cmd\ z} = 0.5rad/s$ }和{情况3: $v_{cmd\ x} = 0.5m/s$, $w_{cmd\ z} = 0.5rad/s$ }。它们在测试过程中保持恒定。

另一方面，机械臂所需目标位置的初始值是从尺寸为 $[0.25 \times 0.2 \times 0.35]\text{m}^3$ 、原点为 $[0.25, 0, 0.15]\text{m}$ 的立方体中随机选择的。然后初始目标在此范围内以较小的步长随机传播，产生长度为500的连续目标轨迹。采样率为50hz，重复运行2024次测试以避免偏差。该测试旨在模仿机器人在移动其底座的同时跟踪动态目标的场景。如图4所示，我们的方法可以以很小的误差跟踪命令。即使对于移动目标，它也能快速收敛到所需的轨迹。C.真实机器人测试我们通过在物理机器人上测试训练后的策略以完成各种任务来进一步验证训练后的策略，如图1所示。与模拟过程中的随机生成相比，基本速度和操纵臂姿势所需的控制命令是通过用户输入提供的，以完成不同的任务。根据这些命令的来源，我们的实验可以分为以下几类：1) 远程操作：使用遥控手柄提供控制命令。

机器人可以跟踪这些指令来完成以下任务。a) 开门任务：该任务包括接近门把手、旋转门把手、推或拉门以及移动。b) 风扇抽动任务：该任务涉及接近风扇、推动并抽动旋钮。2) 动态操纵：除了人机交互生成的命令之外，动态跟踪的挑战性任务是通过获取根据相机提供的反馈计算出的命令来完成的。机械臂末端的夹具上安装有 RGB 摄像头，引导机器人朝接力棒方向移动并捕捉接力棒。机械臂快速跟踪接力棒的运动，并最终使用所提出的结构抓住它，突出了我们的算法在将机器人的底盘移动性与机械臂的动态运动相结合方面的优势。D. 消融研究为了评估我们提出的结构的不同因素的重要性，我们对我们的方法中两个最重要的组件进行了消融测试。1) 有/没有课程学习：图5显示了整个训练过程中的奖励和平均动作噪声标准差。很明显，我们的框架结合了所提出的奖励意识课程学习，获得了更高的奖励，并减少了行动的随机性。

图 5. 课程学习对奖励和行动的影响 2) 有/没有 Arm-Constrained Critic Network: 为了评估约束网络的重要性，我们将我们的方法与仅奖励 PPO 框架进行了比较分析，所有训练参数保持相同。如图 6 所示，我们的方法显着促进了更安全的运动并减少了机械臂所有关节的振动。与基线方法相比，机械臂的动作不太可能违反大多数关节的关节限制（只有连接到夹具的 J6 关节似乎比基线更违反限制，但这可能是尝试平衡手臂质心和底座质心的结果）。图 6. 手臂约束 VI 的效果。结论 总之，本文提出了一种用于轮腿机器人局部操纵的强化学习框架，使它们能够在高度动态的情况下执行一系列复杂的操纵任务。我们强调将手臂纳入系统所带来的额外挑战。首先，AC-PPO的设计是为了确保控制性能的安全性和稳定性。

其次，提出了一种奖励感知课程学习算法来解决手臂和底座之间奖励设置的差异。该结构在仿真中表现出较高的跟踪精度。最后，我们通过完成基本的远程操作任务和动态操纵任务来展示该架构在现实世界中的熟练程度。未来，我们将将该架构实现并扩展至多智能体协作任务。参考文献 [1] F. Jenelten, J. He, F. Farshidian 和 M. Hutter, “Dtc: 深度跟踪控制”, 《科学机器人》, 卷。9、不。86, p. eadh5401, 2024. [2] M. Geilinger, S. Winberg 和 S. Coros, “用于设计熟练的腿轮机器人的计算框架”, IEEE 机器人与自动化快报, 卷。5、没有。2, 第 3674-3681 页, 2020 年。

[3] Z. Fu, X. Cheng 和 D. Pathak, “深度全身控制: 学习操纵和运动的统一策略”, 机器人学习会议。PMLR, 2023 年, 第 138-149 页。[4] F. Raza, W. Zhu 和 M. Hayashibe, “通过手臂加速控制增强轮腿双足机器人的平衡稳定性”, IEEE Access, 卷。9, 第 54 022-54 031 页, 2021 年。[5] Q. Chang, X. Liu, W. Xu, L. Yan, B. Yang, “带有两个机械臂的小型轮腿移动机器人系统的设计和实验”, 发表于 IEEE/RSJ 国际智能机器人与系统会议 (IROS), 2016 年, 第 2590-2595 页。[6] S.王, L.崔, J.张, J.赖, D.张, K.陈, Y.郑, Z.张, 和Z.-P。

Jiang, “新型轮腿机器人的平衡控制: 设计与实验”, IEEE 国际机器人与自动化会议 (ICRA), 2021 年, 第 6782-6788 页。[7] E. F. Morales, R. Murrieta-Cid, I. Becerra 和 M. A. Esquivel-Basaldúa, “机器人技术中深度学习和深度强化学习的调查以及深度强化学习教程”, 智能服务机器人, 卷。14、没有。5, 第 773-805 页, 2021 年。[8] C. 张, J. Jin, J. Frey, N. Rudin, M. E. Mattamala Aravena, C. Cadena 和 M. Hutter, “弹性腿本地导航: 学习以妥协的感知端到端进行遍历”, 第 41 届 IEEE 机器人与自动化会议 (ICRA), 2024 年。

[9] N. Rudin, D. Hoeller, P. Reist 和 M. Hutter, “使用大规模并行深度强化学习在几分钟内学会走路”, 2021 年 09 月。[10] V. Tsounis, M. Alge, J. Lee, F. Farshidian 和 M. Hutter, “Deepgait: 使用深度强化学习规划和控制四足步态”, IEEE 机器人与自动化快报, 卷。5、没有。2, 第 3699-3706 页, 2020 年。[11] J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun 和 M. Hutter, “在具有挑战性的地形上学习四足运动”, 《科学机器人》, 卷。5、没有。47, p. eabc5986, 2020。

[12] J. Hwangbo, J. Lee, A. Dosovitskiy, D. Bellicoso, V. Tsounis, V. Koltun 和 M. Hutter, “学习腿式机器人的敏捷和动态运动技能”, 《科学机器人》, 卷. 4, 没有. 26, p. eaau5872, 2019. [13] Y. Yang, K. Caluwaerts, A. Iscen, T. Zhu, J. Tan 和 V. Sindhwani, “腿式机器人的数据高效强化学习”, 机器人学习会议. PMLR, 2020 年, 第 1-10 页. [14] L. Schneider, J. Frey, T. Miki 和 M. Hutter, “使用分布式强化学习学习风险感知四足运动”, 第 41 届 IEEE 机器人与自动化会议 (ICRA), 2024 年。

[15] T. Miki, J. Lee, J. Hwangbo, L. Wellhausen, V. Koltun 和 M. Hutter, “学习鲁棒感知四足机器人在野外的运动,” 《科学机器人》, 卷. 7, 没有. 62, p. eabk2822, 2022. [16] S. Choi, G. Ji, J. Park, H. Kim, J. Mun, J. H. Lee 和 J. Hwangbo, “在可变形地形上学习四足运动”, 《科学机器人》, 卷. 8, 不. 74, p. eade2256, 2023. [17] X. B. Peng, E. Coumans, T. Zhang, T.-W. E. Lee, J. Tan 和 S. Levine, “通过模仿动物学习敏捷机器人运动技能”, 《机器人学: 科学与系统》, 2020 年 7 月。

[18] E. Farnioli, M. Gabiccini 和 A. Bicchi, “走向全身运动操纵: 与步行机器人多接触交互的实验结果”, 2016 年 IEEE/RSJ 国际智能机器人和会议系统 (IROS)。IEEE, 2016 年, 第 1372-1379 页. [19] Y. Wu, P. Balatti, M. Lorenzini, F. Zhu, W. Kim 和 A. Ajoudani, “用于移动协作机器人助手局部操纵控制的远程操作接口”, IEEE 机器人与自动化快报, 卷. 4, 没有. 4, 第 3593-3600 页, 2019 年。

[20] Y. Ma, F. Farshidian 和 M. Hutter, “学习手臂辅助跌落损伤减少和腿式移动机械臂恢复”, 2023 年 IEEE 国际机器人与自动化会议 (ICRA), 2023 年, 第 12 149-12 155 页. [21] J.-P. Sleiman, F. Farshidian 和 M. Hutter, “用于腿式局部操纵的多功能多接触规划和控制”, 《科学机器人》, 卷. 8, 不. 81, p. eadg5014, 2023。

[22] Y. Ma, F. Farshidian, T. Miki, J. Lee 和 M. Hutter, “将基于学习的运动策略与基于模型的移动策略相结合anipulation for Legged mobile manipulators,”IEEE 机器人与自动化快报, 第 7 卷, 第 2 期, 第 2377-2384 页, 2022 年. [23] E. Altman, 约束马尔可夫决策过程. Routledge, 2021 年. [24] Y. Kim, H. Oh, J. Lee, J. Choi, G. Ji, M. Jung, D. Youm 和 J. Hwangbo, “不仅是奖励, 还有约束: 在腿式机器人运动中的应用”, arXiv 预印本 arXiv: 2308.12517, 2023。

[25] J. Lee, L. Schroth, V. Klemm, M. Bjelonic, A. Reske 和 M. Hutter, “腿式运动的约束强化学习算法的评估”, arXiv 预印本 arXiv: 2309.15430, 2023. [26] L. Zhang, L. Shen, L. Yang, S. Chen, X. Wang, B. Yuan, 和 D. Tao, “安全强化学习的惩罚近端策略优化”, 2022 年 7 月, 第 3719-3725 页. [27] Z. Xie, H. Y. Ling, N. H. Kim 和 M. van de Panne, “Allsteps: 课程驱动的垫脚石技能学习”, 《计算机图形学论坛》, 第 39 卷, 第 8 期。

Wiley 在线图书馆, 2020 年, 第 213-224 页 [28] Y. Bengio, J. Louradour, R. Collobert 和 J. Weston, 《课程学习》, 第 26 届国际机器学习会议记录. 2009 年, 第 41-48 页. [29] E. Todorov, T. Erez 和 Y. Tassa, “Mujoco: 基于模型控制的物理引擎”, IEEE/RSJ 国际智能机器人和系统会议, 2012 年, 第 5026-5033 页。